

Monitoreo transaccional: ¿el orden de las transacciones vale la pena?

Informe para el comité de riesgos — Banco del Altiplano

Luis Pedro Lira · Mario Rocha | Universidad del Valle, Deep Learning 2026

Pregunta del comité: ¿el orden de las transacciones de una tarjeta aporta información que las variables agregadas actuales (monto promedio 24h, transacciones por hora, monto máximo del día, diversidad de comercios) no capturan, y cuánto vale esa información en quetzales? Este informe responde con evidencia, no con una recomendación de arquitectura.

Resumen ejecutivo: sí aporta. Un modelo que lee la secuencia de eventos (Modelo B) separa mejor el fraude que el modelo actual basado solo en agregados (Modelo A), y cuando se destruye artificialmente el orden de esos mismos eventos, el desempeño del modelo se desploma — la señal no viene de qué transacciones hay, sino de en qué orden llegan. Se recomienda **complementar** el sistema actual con un modelo secuencial, con un ahorro adicional estimado de casi Q100,000 al mes sobre lo que ya ahorra el enfoque de agregados.

1 Integridad de datos

Se trabajó con datos sintéticos generados con semilla fija (reproducibles: dos corridas con la misma semilla producen el mismo dataset, fila por fila) — 8,000 clientes, 180 días, **436,931 transacciones**, tasa de fraude **1.24%**. Se inyectaron tres tipos de fraude como episodios cortos sobre la línea de tiempo de un cliente:


- **Sondeo y fuga** — depende del *orden*: varias compras pequeñas (Q5–40) seguidas de una compra grande. Incluye una variante “lenta” deliberadamente difícil (horas en vez de minutos entre eventos, salto de monto menos extremo) — el caso donde se esperaba que el modelo fallara.
- **Ráfaga en categorías de alto riesgo** — montos altos concentrados en categorías ya marcadas como riesgosas; detectable en gran medida sin ver el orden.
- **Salto de canal** — episodio de monto moderado por un canal distinto al habitual del cliente, patrón típico de toma de cuenta.

Partición **estrictamente temporal** (70/15/15): lo más antiguo entrena, lo intermedio valida, lo más reciente prueba — sin solapamiento verificado por código. Toda variable agregada usa solo historia *previa* a la transacción que describe; todo ajuste de escalamiento (numéricas y umbral de decisión) se calculó únicamente con el conjunto de entrenamiento o de validación, nunca con estadísticas del conjunto completo. El conjunto de prueba se miró una sola vez, después de fijar arquitectura, umbral y criterio de éxito de la apuesta del equipo.

2 Comparación común: Modelo A vs. Modelo B

Modelo A (línea base, sin orden): boosting de árboles sobre las variables agregadas del motor actual más un par de derivadas (ratio de monto contra el propio historial, hora, día de la semana). **Modelo B** (secuencial): una red recurrente (GRU) que recibe, en orden, los últimos 10 eventos crudos de la tarjeta (monto, categoría, canal, hora, tiempo desde la transacción anterior) — deliberadamente *sin* los agregados de A, para que cualquier ventaja de B se deba al orden y no a tener acceso a la misma información que A. Ambos devuelven un puntaje continuo; el umbral de cada uno se fijó minimizando costo económico en validación y se aplicó una sola vez a prueba.

Modelo	AUC-PR	Precisión	Exhaustividad	F1	Umbral
A — agregados (boosting)	0.847	0.441	0.917	0.595	0.05
B — secuencial (GRU)	0.924	0.483	0.940	0.638	0.40




B domina a A en toda la curva precisión-exhaustividad, no solo en un punto — con la misma partición, el mismo horizonte de predicción (por transacción) y la misma función de evaluación.

3 Valor del orden: dos pruebas de falsificación

Una mejora de métricas no prueba que el modelo use el orden — podría estar aprendiendo otra cosa. Se diseñaron dos pruebas para intentar refutar esa lectura.

Prueba 1 (obligatoria) — permutación controlada. Se barajó el orden *dentro* de cada secuencia de prueba, sin tocar los eventos ni sus valores — la ventana contiene exactamente las mismas transacciones, en otro orden. Se evaluó el Modelo B ya entrenado (pesos congelados) sobre estas secuencias barajadas.



	AUC-PR	Precisión	Exhaustividad	F1
Orden original	0.924	0.483	0.940	0.638
Orden barajado	0.070	0.132	0.224	0.166

El AUC-PR cae **92%** al destruir el orden, con los mismos eventos. Esta es la evidencia central: el modelo no está memorizando qué transacciones aparecen en la ventana, está leyendo la secuencia en la que llegan.

Prueba 2 (elegida por el equipo) — desglose por mecanismo de fraude. De los tres tipos de fraude generados, “sondeo y fuga” se diseñó para depender del orden; los otros dos, menos. Si el razonamiento anterior es correcto, la ventaja de B debería concentrarse más en los tipos que dependen de secuencia.

Tipo de fraude	n (prueba)	Exhaustividad A / B	Puntaje prom. A	Puntaje prom. B
Ráfaga alto riesgo	183	0.93 / 0.93	0.79	0.90
Salto de canal	250	0.86 / 0.95	0.73	0.92
Sondeo y fuga	278	0.96 / 0.94	0.80	0.92

La exhaustividad al umbral elegido queda parecida entre A y B en los tres tipos — pero está confundida por el umbral de A, mucho más bajo (0.05), que marca casi cualquier puntaje elevado como fraude a costa de 827 falsos positivos en prueba (contra 714 de B). El **puntaje promedio sin pasar por umbral** es la comparación limpia: B separa más en los tres tipos, y de forma más marcada en salto de canal y sondeo y fuga que en ráfaga de alto riesgo — consistente con la Prueba 1, sin exagerarla: la diferencia por tipo es real pero moderada: la evidencia fuerte de que el orden importa sigue siendo la permutación, no este desglose.

4 Apuesta del equipo

Hipótesis declarada antes de entrenar: “Creemos que combinar la representación secuencial del Modelo B con las variables agregadas causales del Modelo A mejorará el AUC-PR de validación frente al mejor de los dos por separado, porque cada rama captura una señal distinta. Lo consideraremos útil si el AUC-PR de validación del híbrido supera al mejor de A o B en al menos 0.01.”

Control: mismo conjunto de entrenamiento/validación/prueba, mismo criterio de paro anticipado, mismo ‘class_weight’ que B — la única diferencia es una rama adicional con los agregados de A.

	A (val.)	B (val.)	C — híbrido (val.)
AUC-PR	0.836	0.926	0.900

Veredicto: NO ÚTIL. El híbrido no solo no superó el margen de 0.01 exigido — quedó por *debajo* del Modelo B solo. Combinar ambas ramas no ayudó; es posible que la información de los agregados ya esté casi contenida en lo que B aprende directamente de la secuencia cruda, y que la rama adicional le reste capacidad de aprendizaje al resto del modelo en el mismo presupuesto de entrenamiento. Se reporta igual, por transparencia: un resultado negativo declarado de antemano es tan válido como uno positivo, y evita quedarnos con una arquitectura más compleja sin evidencia que la respalde.

5 Decisión económica

Costo mensual estimado = (fraudes no detectados × Q4,200) + (transacciones legítimas bloqueadas × Q180), con el umbral que minimiza ese costo en **validación**, aplicado una sola vez a prueba y escalado a 30 días.

Modelo	Umbral	FN	FP	Costo mensual
A — agregados	0.05	59	827	Q440,733
B — secuencial	0.40	43	714	Q343,467
C — híbrido (no recomendado)	0.68	50	590	Q351,333
Sin modelo (referencia)	—	—	—	Q3,318,000

B ahorra **Q2,974,533/mes** frente a no interceptar nada — casi Q100,000/mes más que A (Q2,877,267/mes) — con *menos* falsos positivos, no solo menos fraude escapado. El híbrido C queda por encima del costo de B: no gana en AUC-PR ni en costo, así que no hay ángulo desde el que recomendarlo sobre B.

Límite explícito: el punto de comparación es “no interceptar nada”, no el motor de reglas real del banco — no se contó con sus predicciones históricas para un contraste directo. El ahorro reportado es frente a ese piso, no frente al sistema en producción.

6 Recomendación y límites

Recomendación: complementar el sistema actual con el Modelo B secuencial, no reemplazarlo de golpe — el margen de mejora es consistente en AUC-PR, en las dos pruebas de falsificación y en costo, pero el modelo no se ha probado contra el motor de reglas real ni contra tráfico en producción.

Patrón de error concreto: en la variante “lenta” de sondeo y fuga (diseñada para ser difícil — el salto de monto es menos extremo y el episodio se extiende por horas, no minutos), el Modelo A le asigna un puntaje promedio notablemente más bajo que al resto del fraude (0.66 contra 0.78), aunque con el umbral tan permisivo que eligió A (0.05) termina igual marcándola casi siempre. Con un umbral más alto o más casos de este tipo, es exactamente el patrón que se le escaparía a A.

Condiciones bajo las que cambiaría esta recomendación: (a) si el motor de reglas real, puesto a competir de verdad, ya cubre casos equivalentes al sondeo y fuga con un costo operativo menor al de mantener un modelo adicional; (b) si aparece un mecanismo de fraude no visto durante el entrenamiento y el desempeño de B se degrada más que el de A al enfrentarlo — no evaluado en este proyecto; (c) si la latencia real de ensamblar la ventana de 10 eventos por transacción no es compatible con el tiempo de decisión del banco.

Matriz de evidencias

Evidencia	Dónde aparece	Conclusión	Limitación
1. Integridad de datos	Sección 1	3 tipos de fraude documentados, reproducible, sin fuga temporal	Datos sintéticos
2. Comparación A vs B	Sección 2, tabla y curva PR	B supera a A en toda la curva	Un solo horizonte de predicción
3. Valor del orden	Sección 3, permutación y desglose	Caída de 92% en AUC-PR al barajar el orden	Desglose por tipo confundido por umbrales distintos
4. Apuesta del equipo	Sección 4	Híbrido no útil, declarado de antemano	Un solo entrenamiento por modelo
5. Decisión económica	Sección 5, tabla de costos	B ahorra Q100k/mes más que A	Comparado contra “no interceptar nada”, no contra reglas reales
6. Recomendación y límites	Sección 6	Complementar con B, no reemplazar	Sin prueba ante fraude no visto ni en producción
